



Universidade de Brasília
Departamento de Estatística

Lista Teórica 1

Carlos César Yoshitake Júnior

Prof. Raul Matsushita

Resolução da lista de exercícios teórica 1.

Brasília
2026

Índice

1	Exercício 1	2
2	Exercício 2	2
3	Exercício 3	2
4	Exercício 4	3
	Referências	5

1 Exercício 1

Uma amostra aleatória simples $X_1, \dots, X_n$ foi retirada de uma população com média μ e variância conhecida σ^2 . Para se testar a hipótese nula $H_0 : \mu = \mu_0$ contra a alternativa $H_0 : \mu \neq \mu_0$, com n suficientemente grande, a estatística do teste sob H_0

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

Em que $\bar{X}$ representa a média amostral, remete a um teste paramétrico ou não paramétrico? Justifique sua resposta.

- *Resposta:*

Com n suficientemente grande, é possível utilizar do Teorema do Limite Central. Assim, pelo TLC, a distribuição da média amostral $\bar{X}$ se aproxima de uma distribuição normal $N(\mu, \sigma^2/n)$, quando $n \rightarrow \infty$, independente de qual seja a distribuição original. Logo, a resposta é não paramétrico, pois um teste paramétrico tradicional exige suposições estritas sobre a distribuição subjacente dos dados, o que não é o caso, uma vez que a aproximação independe da distribuição original.

2 Exercício 2

Um pesquisador deseja comparar duas dietas alimentares A e B para diabéticos. Considerando que o resultado obtido pela dieta depende das variáveis sexo, idade e tempo de diagnóstico da doença:”

- i) Explique, detalhadamente, como ele deve efetuar seu estudo (procedimento de coleta de dados e tabulação)

- *Resposta:*

O pesquisador deve coletar os dados de maneira pareada, com o “match” feito a partir de características similares nas variáveis disponíveis, de forma que o indivíduo X_i da dieta A seja semelhante ao indivíduo Y_i da dieta B. A tabulação deve ser composta por 4 colunas, sendo a primeira o Par i , a segunda a dieta A, a terceira a dieta B e a quarta a diferença entre a $X_i - Y_i$. Esse exercício se assemelha ao exemplo 3.2 do (Hollander, 2014).

- ii) Enumere possíveis testes não paramétricos que sejam adequados para essa comparação

- *Resposta:*

Os testes apontados para esse tipo de situação no (Bonnini, 2014) são o Teste de Wilcoxon, Teste de permutação e Teste dos Sinais de Fisher.

3 Exercício 3

Dezesseis veículos de passeio foram inspecionados em uma operação do Detran em determinado dia no Distrito Federal. Dessa amostra, supostamente aleatória, x veículos foram apreendidos por causa de irregularidades. Explique como você testaria a hipótese (nula) de que o percentual populacional de veículos irregulares no DF é igual ou inferior a

10%.

• *Resposta:*

Através do teste Binomial. Primeiro, definiria X como o número de veículos apreendidos entre os $n = 16$ inspecionados. Sob independência das vistorias, $X \sim \text{Binomial}(16, p)$. Depois definiria as hipóteses: $H_0 : p \leq 0,10$ e $H_1 : p > 0,10$. Assim, é possível calcular o p -valor usando o código:

```
binom.test(x=10, n=16, p=0.1, alternative = "greater")
```

Note que, $x = 10$ é um número arbitrário que representa a quantidade de veículos apreendidos na amostra, e deve ser substituído pelo valor observado real.

4 Exercício 4

Dez amostras de água foram retiradas de diferentes reservatórios de uma estação de tratamento de água, registrando-se os valores $X_1, \dots, X_{10}$ do pH (potencial de hidrogênio)

- i) Supondo que seja importante que a água tratada tenha um pH mediano igual ou superior a 7, que método você sugere para testar as seguintes hipóteses:

$$H_0 : \text{Med}(X) \leq 7$$

$$H_1 : \text{Med}(X) > 7$$

- *Resposta:*

O (Hollander, 2014) traz, na página 63, no tópico “A Distribution-Free Sign Test (FISHER)”, ou seja, Teste dos Sinais. Assim, compara-se cada uma das $n = 10$ medições de pH com valor 7. Define-se a variável de contagem de sinais positivos $K = \sum I(X_i) > 7$. Sob H_0 , $K \sim \text{Binomial}(n^*, 0.5)$ (desconsiderando observações iguais a 7).

- ii) Agora, suponha que o pH da água tratada deve estar entre 7 e 7.5 em pelo menos 90% dos casos. Para essa situação, como você testaria as seguintes hipóteses:

$$H_0 : P(7 \leq X \leq 7.5) \leq 0.90$$

$$H_1 : P(7 \leq X \leq 7.5) > 0.90$$

- *Resposta:*

Para testar casos onde uma proporção de valores devem estar dentro de um intervalo específico o Teste Binomial é o mais indicado. No (Hollander, 2014), página 11-22 esse teste é explicado na íntegra. Logo, os seguintes passos devem ser seguidos:

- 1: Criação de variável indicadora Y_i para cada uma das $n = 10$ medições de pH ($X_1, \dots, X_{10}$), que recebe valor 1 caso a medição esteja dentro do intervalo desejado (No caso, $7 \leq X_n \leq 7.5$) recebe 1, e 0 caso contrário)
- 2: Define-se $p = P(7 \leq X \leq 7.5)$ como a probabilidade populacional de uma amostra ter o pH no intervalo ideal. A estatística do teste é a contagem do número total de sucessos:

$$\sum_{i=1}^{10} Y_i \sim \text{Binomial}(10, p)$$

- 3: Define-se as hipóteses associadas:

$$H_0 : p \leq 0.90$$

$$H_1 : p > 0.90$$

- 4: Sob a fronteira de H_0 ($p = 0.90$), o valor-p unilateral a direita para y_{obs} sucessos observados na amostra é dado por:

$$valor - p = P(Y \geq y_{obs} | p = 0.90) = \sum_{k=y_{obs}}^{10} \binom{10}{k} (0.90)^k (0.10)^{10-k}$$

Exercício 5

O teste de Kolmogorov-Smirnov é tradicionalmente utilizado para avaliar a aderência de uma amostra a uma distribuição de probabilidade contínua.

- i) Explique por que a presença de observações empatadas pode se tornar inadequada a aplicação do teste de Kolmogorov-Smirnov em sua forma usual para testar a hipótese de normalidade, como está implementado, por exemplo, na função `ks.test()` do R.

• *Resposta:*

O teste de Kolmogorov-Smirnov clássico para uma amostra é um procedimento não paramétrico de aderência (goodness-of-fit) projetado para avaliar se os dados de uma amostra provêm de uma população com uma distribuição de probabilidade $F_0(x)$ especificada.

Para que a distribuição nula exata do teste KS clássico seja válida, o procedimento estabelece duas restrições:

- Continuidade estrita da população: A variável deve ser contínua, o que implica que a probabilidade teórica de ocorrência de empates é **nula** $P(X_i = X_j) = 0$;
- Parâmetros totalmente especificados a priori: A distribuição $F_0(x)$ sob a hipótese nula $H_0 : F(x) = F_0(x)$ não possui parâmetros desconhecidos; todos seus parâmetros (por exemplo, μ e σ) devem ser fixados teoricamente antes do teste, sem serem **estimados da própria amostra**.

Assim, a partir da restrição da Continuidade estrita da população o teste de Kolmogorov-Smirnov clássico se torna inadequado para presença de observações empatadas, pois essas observações trazem alterações nos saltos da Distribuição Empírica ($\hat{F}_n$): Quando ocorrem empates (devido a arredondamentos, limites de precisão do instrumento de medição ou dados discretizados), a Função de Distribuição Acumulada Empírica ($\hat{F}_n$) deixa de ter apenas degraus individuais de tamanho $1/n$ e dá saltos múltiplos (de tamanho k/n) no mesmo ponto. Dessa forma, o teste se torna conservador, uma vez que a alteração nos degraus modifica a distribuição nula exata da estatística de teste $D = \max |F_n(x) - F_0(x)|$. Como consequência, a utilização da tabela clássica do KS torna o teste conservador, ou seja, o nível de significância real fica abaixo do nível nominal estipulado, reduzindo o poder do teste.

- ii) Discuta possíveis soluções para realização de um teste de normalidade quando a amostra apresenta observações empatadas. Considere, em particular, situações que os empates são decorrentes da precisão ou do arredondamento do instrumento de medida.

• *Resposta:*

Quando ocorrem empates decorrentes da precisão ou do arredondamento do instrumento de medição, o teste de Kolmogorov-Smirnov em sua forma assintótica usual torna-se inadequado. Para contornar essa limitação, os materiais da disciplina e a literatura especializada indicam as seguintes soluções:

- Teste de Kolmogorov-Smirnov por Simulação de Monte Carlo: Para contornar a invalidade das tabelas clássicas quando os parâmetros populacionais (μ e σ) são estimados a partir da amostra e há empates, obtém-se a distribuição nula empírica da estatística D gerando-se B amostras independentes $N(0, 1)$ de tamanho n . Em cada réplica, reestimam-se $\bar{X}^{(b)}$ e $S^{(b)}$ e calcula-se a estatística $D^{(b)}$. O valor- p de Monte Carlo é dado pela proporção de réplicas em que a discrepância simulada supera a observada:

$$\hat{p} = \frac{1 + \sum_{b=1}^B I(D^{(b)} \geq D_{\text{obs}})}{B + 1}$$

- Teste de Lilliefors (`nortest::lillie.test`): Trata-se de uma adaptação do teste KS desenvolvida para testar normalidade com média e variância desconhecidas e estimadas dos dados. Esse teste utiliza tabelas e quantis críticos ajustados que acomodam observações com empates discretizados por arredondamento.
- Teste de Shapiro-Wilk (`shapiro.test`): Mede o grau de aderência linear entre as estatísticas de ordem observadas $X_{(i)}$ e os valores esperados das estatísticas de ordem normais padrão (m_i). É um dos testes não paramétricos de aderência mais poderosos para amostras pequenas e médias, demonstrando elevada robustez diante de empates causados pela precisão do instrumento.
- Teste de Anderson-Darling (`nortest::ad.test`): Avalia a distância entre a FDAE e a normal ajustada aplicando o fator de ponderação $\frac{1}{F_0(x)[1-F_0(x)]}$, o que confere maior sensibilidade a discrepâncias localizadas nas caudas da distribuição. Lida bem com dados com arredondamento e utiliza tabelas ajustadas para parâmetros estimados.
- Técnica de Jittering (Perturbação Aleatória Mínima): Adiciona-se a cada observação empatada um ruído aleatório contínuo $U(-\epsilon, \epsilon)$, com ϵ inferior ao limite de resolução do instrumento de medida, desfazendo os empates numéricos sem alterar a forma funcional da distribuição.

Referências

BONNINI, Marozzi, Corain. **Nonparametric Hypothesis Testing - Rank and Permutation Methods with Applications in R**. [S.l.]: Wiley, 2014.

HOLLANDER, Chicken, Wolfe. **Nonparametric Statistical Methods**. [S.l.]: Wiley, 2014.